

Μια μεθοδολογία εξαγωγής σήματος σε αντι-επαγωγικές αγορές

Τρία στρώματα πειθαρχίας --- με απλά μαθηματικά και αριθμητικά παραδείγματα

Stefanos Drakos
AGEL AI I.K.E., Ρόδος
ORCID: 0000-0001-7417-2444

4 Ιουνίου 2026

Περίληψη

Το κείμενο μετατρέπει τις διαπιστώσεις της In Young Cho (Jane Street, Signals & Threads, 2025) για τη μηχανική μάθηση στις αγορές σε μια συγκεκριμένη, εφαρμόσιμη μεθοδολογία. Η κεντρική ιδέα είναι ότι το πρόβλημα --- η εξαγωγή ενός μικρού, φθίνοντος σήματος μέσα σε ακραίο θόρυβο --- λύνεται μόνο με *τρία συντονισμένα στρώματα πειθαρχίας*: στην είσοδο, στον στόχο και στην αξιολόγηση, μαζί με έναν βρόχο προσαρμογής στις αλλαγές καθεστώτος. Κάθε στρώμα παρουσιάζεται με διαισθητική εξήγηση, μία απλή εξίσωση και ένα αριθμητικό παράδειγμα δουλεμένο βήμα-βήμα. Τα δύο μας προηγούμενα άρθρα (Differential Entropic Reward, Belief-State RL) γίνονται τα δύο πρώτα στρώματα· το τρίτο --- η πειθαρχία αξιολόγησης --- είναι το κομμάτι που συνήθως λείπει.

1 Το πρόβλημα, με ένα νούμερο

Η In Young Cho δίνει μια εικόνα: στα χρηματοοικονομικά είναι σαν να έχεις 100 μονάδες δεδομένων, αλλά μόνο 1 είναι χρήσιμη και οι 99 θόρυβος --- και δεν ξέρεις ποια είναι ποια. Ας το κάνουμε αριθμό. Αν η διακύμανση του πραγματικού σήματος είναι 1 και του θορύβου 99, το ποσοστό της μεταβλητότητας που μπορεί να εξηγήσει *οποιοδήποτε* μοντέλο είναι

$$R^2 = \frac{\text{Var}(\text{σήμα})}{\text{Var}(\text{σήμα}) + \text{Var}(\text{θόρυβος})} = \frac{1}{1 + 99} = 0,01 = 1\%.$$

Ένα R^2 της τάξης του 1% δεν είναι αποτυχία· είναι το *φυσιολογικό* στις αγορές. Σε αυτό προστίθενται δύο ακόμη παθογένειες:

- **Αλλαγές καθεστώτος**: σε αντίθεση με την αναγνώριση ψηφίων, η κατανομή των δεδομένων αλλάζει --- κρίση σχεδόν κάθε χρόνο.
- **Αντι-επαγωγικότητα** (Lo, 2004): μόλις βρεις μια κανονικότητα, την εκμεταλλεύεσαι, και αυτό την σβήνει. Το ίδιο το σύστημα αφαιρεί από το μέλλον ό,τι ήταν προβλέψιμο στο παρελθόν.

Η κεντρική ιδέα. Ο Ron Minsky παρατηρεί ότι η πειθαρχία ζει είτε στον *χώρο του μοντέλου* (απλά μοντέλα, priors --- όταν τα δεδομένα είναι λίγα) είτε στον *χώρο δεδομένων/αξιολόγησης* (αυστηρό out-of-sample --- όταν τα μοντέλα είναι σύνθετα). Όσο μεγαλώνει η πολυπλοκότητα, χρειάζεσαι **και τα δύο**. Η μεθοδολογία μας τα οργανώνει σε τρία στρώματα.

Σχηματικά. Η ροή είναι: *θορυβώδη δεδομένα* → [**Στρώμα 1: φίλτρο**] → καθαρότερη εκτίμηση κατάστασης → [**Στρώμα 2: risk-sensitive στόχος**] → απόφαση/θέση → [**Στρώμα 3: τίμια αξιολόγηση**] → απόφαση αν θα βγει στην παραγωγή. Ο **βρόχος καθεστώτος** τρέχει παράλληλα και ενημερώνει το φίλτρο.

2 Στρώμα 1 --- Πειθαρχία εισόδου: ξεχώρισε σήμα από θόρυβο

Ιδέα. Μην κάνεις απόφαση πάνω στις θορυβώδεις τιμές. Πρώτα *φιλτράρισε* για να βγάλεις μια καθαρότερη εκτίμηση της κρυφής «αληθινής» κατάστασης, μαζί με μια εκτίμηση του *πόσο* την εμπιστεύεσαι. Αυτό κάνει ο γραμμικός φίλτρο Kalman (1960): δεν είναι ένας ad-hoc κινητός μέσος, αλλά ένας ζυγαριά μεταξύ της πρόβλεψής σου και της νέας παρατήρησης, με βάρη που προκύπτουν από τις αβεβαιότητες.

Η εξίσωση (βαθμωτή μορφή). Έχεις μια πρότερη εκτίμηση $\hat{x}$ με αβεβαιότητα (διακύμανση) P , και μια νέα παρατήρηση z με θόρυβο μέτρησης διακύμανσης R . Το κέρδος *Kalman* και η ενημέρωση είναι:

$$K = \frac{P}{P + R}, \quad \hat{x}_{\text{νέο}} = \hat{x} + K(z - \hat{x}), \quad P_{\text{νέο}} = (1 - K)P.$$

Το K λέει «πόσο να ακούσω τη νέα παρατήρηση». Αν ο θόρυβος R είναι μεγάλος, K μικρό: εμπιστεύεσαι την πρόβλεψή σου. Αν R μικρό, K μεγάλο: ακούς την παρατήρηση.

Αριθμητικό παράδειγμα. Έστω εκτίμηση τιμής $\hat{x} = 100$ με $P = 4$, και παρατήρηση $z = 106$ με θόρυβο $R = 9$. Τότε

$$K = \frac{4}{4 + 9} = 0,3077, \quad \hat{x}_{\text{νέο}} = 100 + 0,3077(106 - 100) = 101,85, \quad P_{\text{νέο}} = (1 - 0,3077) \cdot 4 = 2,77.$$

Παρότι η αγορά «φώναξε» 106, το φίλτρο μετακινείται μόνο στο 101,85 --- γιατί ο θόρυβος ($R = 9$) είναι μεγαλύτερος από την αβεβαιότητά μας ($P = 4$). Ταυτόχρονα η αβεβαιότητα *πέφτει* από 4 σε 2,77: μάθαμε κάτι. Αυτό ακριβώς σημαίνει «εξάγω σήμα από τον θόρυβο».

Σύνδεση με τη δουλειά μας. Στο άρθρο Belief-State RL αντιμετωπίζουμε το trading ως POMDP: ο RL πράκτορας δρα πάνω στο *belief* $b_t = p(x_t \mid \text{παρατηρήσεις})$ --- στην φιλτραρισμένη κατάσταση --- όχι στις θορυβώδεις τιμές. Στον Θεμελιώδη Νόμο της Ενεργητικής Διαχείρισης (Grinold, 1989) αυτό ανεβάζει τον συντελεστή πληροφορίας (IC) και προστατεύει τον συντελεστή μεταφοράς (TC), χωρίς να αλλάζει το breadth.

Η σκληρή αλήθεια (τίμιο score). Το φίλτρο *εξάγει* καθαρότερα ένα σήμα --- δεν *δημιουργεί* σήμα. Αν το υποκείμενο σήμα δεν υπάρχει, κανένα φίλτρο δεν θα το βρει.

3 Στρώμα 2 --- Πειθαρχία στόχου: μη μεγιστοποιείς το μέσο κέρδος

Ιδέα. Σε υψηλό θόρυβο, το «μεγιστοποίησε το μέσο κέρδος» είναι παγίδα: προτιμά στρατηγικές που τυχαία πήγαν καλά αλλά είναι ασταθείς. Αντί γι' αυτό, βελτιστοποιούμε έναν στόχο που *τιμωρεί τη μεταβλητότητα*. Μια απλή, διαισθητική μορφή του *εντροπικού ισοδυνάμου βεβαιότητας* (η βάση του Differential Entropic Reward) είναι:

$$CE = \mu - \frac{\gamma}{2} \sigma^2,$$

όπου μ η μέση απόδοση, σ η μεταβλητότητά της, και $\gamma > 0$ ο βαθμός αποστροφής κινδύνου. Όσο μεγαλύτερο το γ , τόσο πιο αυστηρά τιμωρείται το ρίσκο.

Αριθμητικό παράδειγμα. Δύο στρατηγικές με *ίδια* μέση απόδοση $\mu = 1,0\%$:

Στρατηγική	μ	σ	Sharpe = μ/σ	CE ($\gamma=10$)	CE ($\gamma=25$)
A	1,0%	1,0%	1,00	0,95%	0,875%
B	1,0%	4,0%	0,25	0,20%	-1,0%

Το «μέσο κέρδος» τις βαθμολογεί ίσες. Ο δείκτης Sharpe και το CE δείχνουν ότι η A είναι πολύ καλύτερη. Με αυστηρή αποστρόφη κινδύνου ($\gamma = 25$), το CE της B γίνεται *αρνητικό*: η μεθοδολογία την απορρίπτει. Π.χ. για την B, $CE = 0,01 - \frac{25}{2}(0,04)^2 = 0,01 - 0,02 = -0,01$.

Σύνδεση. Αυτή είναι η γενίκευση του *differential Sharpe* (Moody & Saffell, 2001) που χρησιμοποιεί το DER paper. Η γέφυρα με τον στοχαστικό έλεγχο συνεχούς χρόνου (Wang, Zariphoroulou & Zhou, 2020) δίνει στο reward ερμηνεία λύσης μιας εξίσωσης HJB με εντροπική κανονικοποίηση.

4 Στρώμα 3 --- Πειθαρχία αξιολόγησης: η αντι-επαγωγική άμυνα

Εδώ είναι το κομμάτι που συνήθως λείπει --- και που η In Young Cho τονίζει περισσότερο. Το πρόβλημα: αν δοκιμάσεις πολλές στρατηγικές, η καλύτερη θα φαίνεται εντυπωσιακή *από καθαρή τύχη*.

Η εξίσωση (διδασκαλική). Αν δοκιμάσεις N εντελώς *άχρηστες* στρατηγικές (αληθινό Sharpe = 0), το αναμενόμενο μέγιστο « z » που θα δεις από τύχη είναι περίπου

$$\mathbb{E}[\max z] \approx \sqrt{2 \ln N}.$$

Πολλαπλασιάσε το με το τυπικό σφάλμα του Sharpe σε backtest T ετών, $SE \approx \sqrt{1/T}$, και παίρνεις το «καλύτερο-από-τύχη» Sharpe.

Αριθμητικό παράδειγμα. Με $T = 10$ έτη, $SE \approx \sqrt{1/10} = 0,316$:

N (δοκιμές)	$\mathbb{E}[\max z] \approx \sqrt{2 \ln N}$	καλύτερο Sharpe από τύχη	naive t
1	0,00	0,00	0,00
20	2,45	0,77	2,45
100	3,04	0,96	3,04

Με μόλις 20 άχρηστες στρατηγικές, η καλύτερη δίνει $t \approx 2,45$ --- περνάει καθαρά το παλιό κατώφλι « $t > 2$ » χωρίς να υπάρχει κανένα σήμα. Γι' αυτό οι Harvey, Liu & Zhu (2016) απαιτούν $t > 3,0$: παρατήρησε ότι το $N = 100$ φτάνει ακριβώς εκεί.

Τα εργαλεία της πειθαρχίας αξιολόγησης:

1. **Combinatorial Purged Cross-Validation** με purging και embargo (López de Prado, 2018): εξαλείφει το look-ahead bias και τη διαρροή όταν τα labels εξαρτώνται από μελλοντικά γεγονότα --- και αποδεδειγμένα προλαμβάνει τις ψευδείς ανακαλύψεις καλύτερα από το απλό walk-forward.
2. **Deflated Sharpe Ratio** (Bailey & López de Prado, 2014): διορθώνει για selection bias, πλήθος δοκιμών, μήκος δείγματος και μη-κανονικότητα.
3. **Κατώφλι πολλαπλών δοκιμών** $t > 3,0$ (Harvey, Liu & Zhu, 2016).
4. «**Προϋπολογισμός υποθέσεων**» σε **επίπεδο ομάδας**: αν πολλοί ερευνητές δοκιμάζουν παρόμοιες ιδέες, διαρρέεις out-of-sample χωρίς να το ξέρεις. Λύση: προεγγραφή (pre-registration) και «κλείδωμα» προ-διαγραφών πριν το backtest.

5 Ο βρόχος καθεστώτος: προσαρμογή στη μη-στασιμότητα

Ιδέα. Το καθεστώς της αγοράς (π.χ. «ήρεμο» ή «ταραγμένο») δεν παρατηρείται άμεσα --- το *συμπεραίνεις* από τα δεδομένα και κρατάς μια *πεποίθηση* (πιθανότητα) γι' αυτό, την οποία ενημερώνεις με τον κανόνα του Bayes.

Αριθμητικό παράδειγμα. Έστω πρότερη πεποίθηση ότι είμαστε σε ταραγμένο καθεστώς $P(\text{ταρ.}) = 0,10$. Μια μεγάλη κίνηση είναι πιθανή στο ταραγμένο ($P(\text{κίνηση} \mid \text{ταρ.}) = 0,5$) και σπάνια στο ήρεμο ($P(\text{κίνηση} \mid \text{ήρ.}) = 0,05$). Μετά από μία μεγάλη κίνηση:

$$P(\text{ταρ.} \mid \text{κίνηση}) = \frac{0,5 \cdot 0,10}{0,5 \cdot 0,10 + 0,05 \cdot 0,90} = \frac{0,050}{0,095} = 0,53.$$

Μία μόνο παρατήρηση εκτόξευσε την πεποίθηση από 10% σε 53%. Αυτό τροφοδοτεί πίσω το φίλτρο του Στρώματος 1 (αλλάζει τα R, γ).

Εργαλεία: Markov regime-switching (Hamilton, 1989), Bayesian Online Changepoint Detection (Adams & MacKay, 2007). Και η *interventional interpretability* (όρος Minsky): κράτα το πάνω στρώμα του μοντέλου αρκετά απλό ώστε σε σπάνια γεγονότα ($N = 1$, π.χ. πανδημία) να μπορείς να αλλάξεις παραμέτρους «με το χέρι».

6 Δύο ακόμη αρχές

Priors & transfer (λίγα δεδομένα). Όπου τα δεδομένα είναι ελάχιστα, η πειθαρχία γυρνά στον χώρο του μοντέλου: Bayesian priors και μεταφορά γνώσης από άλλες κατηγορίες περιουσιακών στοιχείων («είσαι λιγότερο φτωχός σε δεδομένα απ' ό,τι νομίζεις»). Δεν είμαστε πλήρως «Bitter-Lesson-πεπεισμένοι»: κλιμακώνουμε όπου μπορούμε, σχεδιάζουμε priors όπου δεν μπορούμε.

Ρεαλισμός ανάπτυξης (το hardware διαμορφώνει το μοντέλο). Πρώτα όρισε τους περιορισμούς καθυστέρησης/ρυθμαπώδωσης, και μετά διάλεξε το καλύτερο μοντέλο μέσα σε αυτούς --- όχι το αντίστροφο. Ανάπτυξη σε φάσεις: shadow $\rightarrow$ A/B $\rightarrow$ rollout.

7 Σύνοψη και κριτήρια διάψευσης

Με μία πρόταση: το Στρώμα 1 πειθαρχεί την είσοδο (φιλτράρισμα), το Στρώμα 2 τον στόχο (risk-sensitive reward), το Στρώμα 3 την αξιολόγηση (άμυνα στην αντι-επαγωγικότητα), και ο βρόχος καθεστώτος τα κρατά ζωντανά στη μη-στασιμότητα.

Τίμιο scope. Η μεθοδολογία δεν υπόσχεται μαγικό alpha. Με ημερήσια δεδομένα, ο ρεαλιστικός στόχος είναι ένας λόγος πληροφορίας (IR) $\approx 0,5$ έως 1,0 --- ένα νόμιμο ποσοτικό προϊόν. Κριτήριο διάψευσης: αν μετά την πλήρη πειθαρχία αξιολόγησης (Στρώμα 3) το Deflated Sharpe Ratio δεν είναι σημαντικό, η στρατηγική απορρίπτεται --- και αυτό το αναφέρουμε τίμια, ακόμα κι όταν δεν είναι το αποτέλεσμα που θέλαμε.

Βιβλιογραφία

- [1] In Young Cho & R. Minsky. Finding Signal in the Noise: Machine Learning and the Markets. Signals & Threads (Jane Street), Επεισόδιο 22, 2025.
- [2] A. W. Lo. The Adaptive Markets Hypothesis. Journal of Portfolio Management 30(5):15--29, 2004.
- [3] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. Journal of Basic Engineering 82(1):35--45, 1960. DOI: 10.1115/1.3662552.
- [4] R. C. Grinold. The Fundamental Law of Active Management. Journal of Portfolio Management 15(3):30--37, 1989.
- [5] J. Moody & M. Saffell. Learning to Trade via Direct Reinforcement. IEEE Transactions on Neural Networks 12(4):875--889, 2001.

- [6] H. Wang, T. Zariwopoulou & X. Y. Zhou. Reinforcement Learning in Continuous Time and Space: A Stochastic Control Approach. *Journal of Machine Learning Research* 21(198):1--34, 2020.
- [7] R. T. Rockafellar & S. Uryasev. Optimization of Conditional Value-at-Risk. *Journal of Risk* 2(3):21--41, 2000.
- [8] M. G. Bellemare, W. Dabney & R. Munos. A Distributional Perspective on Reinforcement Learning. *ICML, PMLR* 70:449--458, 2017.
- [9] J. D. Hamilton. A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle. *Econometrica* 57(2):357--384, 1989.
- [10] R. P. Adams & D. J. C. MacKay. Bayesian Online Changepoint Detection. *arXiv:0710.3742*, 2007.
- [11] D. H. Bailey & M. López de Prado. The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting and Non-Normality. *Journal of Portfolio Management* 40(5):94--107, 2014.
- [12] C. R. Harvey, Y. Liu & H. Zhu. ...and the Cross-Section of Expected Returns. *Review of Financial Studies* 29(1):5--68, 2016. DOI: 10.1093/rfs/hhv059.
- [13] M. López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018.
- [14] R. S. Sutton & A. G. Barto. *Reinforcement Learning: An Introduction*. 2η έκδ., MIT Press, 2018.