

Ενισχυτική Μάθηση στις Συναλλαγές:

Αναλυτική Θεωρία για Αρχάριους

ΑΓΕΛ ΑΙ Ι.Κ.Ε., Ρόδος

ΟΡΓΙΔ: 0000-0001-7417-2444

2 Ιουνίου 2026

Αυτό το κείμενο εξηγεί, από το μηδέν και χωρίς προαπαιτούμενα πέρα από το λύκειο, τη θεωρία πίσω από έναν αλγόριθμο που *μαθαίνει μόνος του* να κάνει συναλλαγές και προστατεύεται από τις απότομες πτώσεις. Κάθε νέα έννοια εισάγεται με απλά λόγια, ένα συγκεκριμένο αριθμητικό παράδειγμα, και τον αγγλικό όρο σε παρένθεση ώστε να μπορείς να ψάξεις παραπέρα. Στο τέλος υπάρχει συγκεντρωτικός πίνακας όλων των συμβόλων.

1 Τι πρόβλημα λύνουμε

Έχεις κάποια χρήματα και μια μετοχή της οποίας η τιμή ανεβοκατεβαίνει απρόβλεπτα. Κάθε μέρα πρέπει να αποφασίσεις: να την κρατήσεις, να αγοράσεις κι άλλη, ή να την πουλήσεις. Στόχος σου είναι διπλός: να *αυξήσεις* τα χρήματά σου, αλλά και να *μην καταστραφείς* σε μια ξαφνική κατάρρευση.

Γιατί είναι δύσκολο· Επειδή το μέλλον είναι άγνωστο και η αγορά αλλάζει συμπεριφορά: μια στρατηγική με σταθερούς κανόνες που δούλευε πέρυσι, μπορεί να αποτύχει φέτος. Θα θέλαμε λοιπόν ένα σύστημα που *προσαρμόζεται* — που μαθαίνει από την εμπειρία αντί να ακολουθεί τυφλά κανόνες. Αυτή είναι η ιδέα της ενισχυτικής μάθησης.

2 Ενισχυτική μάθηση (reinforcement learning)

Φαντάσου ότι εκπαιδεύεις έναν σκύλο. Δεν του εξηγείς με λόγια τι να κάνει· τον αφήνεις να δοκιμάσει, και όταν κάνει κάτι καλό του δίνεις μια λιχουδιά (*ανταμοιβή*). Με τον καιρό μαθαίνει μόνος του ποιες ενέργειες φέρνουν ανταμοιβές. Ακριβώς έτσι δουλεύει η **ενισχυτική μάθηση** (reinforcement learning): ένας **πράκτορας** (agent) δοκιμάζει ενέργειες, παίρνει ανταμοιβές, και βελτιώνεται.

Τέσσερα συστατικά, στη γλώσσα των συναλλαγών:

- **Κατάσταση** (state): ό,τι «βλέπει» ο πράκτορας πριν αποφασίσει — π.χ. οι αποδόσεις των τελευταίων ημερών.
- **Ενέργεια** (action): τι κάνει — πόσο αγοράζει ή πουλάει.
- **Ανταμοιβή** (reward): πόσο καλά τα πήγε — ένας αριθμός που του λέει αν η ενέργεια ήταν καλή ή κακή.
- **Πολιτική** (policy): ο «κανόνας απόφασης» που μαθαίνει — η συνάρτηση που μετατρέπει την κατάσταση σε ενέργεια.

Με απλά λόγια: Η ανταμοιβή είναι η ψυχή του συστήματος. Δεν λέμε στον πράκτορα πώς να συναλλάσσεται· του λέμε μόνο *τι θεωρούμε καλό*, και αυτός βρίσκει το πώς. Αν ορίσουμε λάθος την ανταμοιβή, θα μάθει λάθος συμπεριφορά — όσο «έξυπνος» κι αν είναι. Όλο το παρόν κείμενο αφορά το πώς να ορίσουμε *σωστά* την ανταμοιβή.

3 Η θέση και το πραγματικό κέρδος

Πρώτα χρειαζόμαστε λίγο συμβολισμό για τον χρόνο και την τιμή.

Χρόνος και τιμή. Με t συμβολίζουμε τη μέρα ($t = 1, 2, 3, \dots$) και με p_t την τιμή της μετοχής τη μέρα t . Η **απόδοση** (return) είναι το ποσοστό μεταβολής της τιμής:

$$r_t = \frac{p_t - p_{t-1}}{p_{t-1}}.$$

Παράδειγμα: αν η τιμή πάει από 100 σε 102 ευρώ, τότε $r_t = \frac{102-100}{100} = 0,02$, δηλαδή κέρδος 2%.

Η θέση. Η ενέργεια του πράκτορα είναι η **θέση** (position) F_t , ένας αριθμός ανάμεσα στο -1 και το $+1$:

$F_t = +1$: πλήρως αγορασμένος (long), $F_t = -1$: πλήρως πουλημένος (short), $F_t = 0$: εκτός αγοράς.

Το $F_t = 0,5$ σημαίνει μισή θέση αγοράς. Το «πουλημένος» ($F < 0$) σημαίνει ότι κερδίζεις όταν η τιμή πέφτει.

Το κόστος συναλλαγής. Κάθε φορά που αλλάζεις θέση πληρώνεις προμήθεια. Τη συμβολίζουμε με δ . *Παράδειγμα:* $\delta = 0,0005$, δηλαδή 5 χιλιοστά του τοις εκατό ανά μονάδα αλλαγής.

Το κέρδος της στρατηγικής. Το πραγματικό σου κέρδος ή ζημιά τη μέρα t (αγγλικά: trading return) είναι:

$$R_t = \underbrace{F_{t-1} r_t}_{\text{κέρδος της θέσης}} - \underbrace{\delta |F_t - F_{t-1}|}_{\text{κόστος αλλαγής θέσης}}.$$

Παράδειγμα: χθες ήσουν πλήρως αγορασμένος ($F_{t-1} = 1$), η μετοχή ανέβηκε $r_t = 0,02$, και σήμερα μειώνεις τη θέση σε $F_t = 0,5$. Τότε

$$R_t = 1 \cdot 0,02 - 0,0005 \cdot |0,5 - 1| = 0,02 - 0,00025 = 0,01975.$$

Με απλά λόγια: Το κόστος $\delta |F_t - F_{t-1}|$ τιμωρεί την υπερβολική κινητικότητα. Χωρίς αυτό, ο πράκτορας θα άλλαζε θέση νευρικά κάθε μέρα και θα έχανε χρήματα σε προμήθειες.

Η πολιτική. Πώς αποφασίζει ο πράκτορας; Παίρνει την κατάσταση x_t (π.χ. τις τελευταίες αποδόσεις), τη συνδυάζει με κάποια **βάρη** w (αριθμούς που μαθαίνει) και τη «στριμώχνει» στο $[-1, 1]$ με τη συνάρτηση $\tanh$:

$$F_t = \tanh(w^\top x_t + b).$$

Η $\tanh$ είναι απλώς ένα «χωνί» που μετατρέπει κάθε αριθμό σε κάτι μέσα στο $[-1, 1]$: $\tanh(0) = 0$, $\tanh(2) \approx 0,96$, $\tanh(-2) \approx -0,96$. Τα βάρη w και η σταθερά b είναι αυτά που η μάθηση ρυθμίζει σιγά-σιγά.

4 Από το κέρδος στον κίνδυνο

Ας πούμε ότι δύο στρατηγικές βγάζουν κατά μέσο όρο το ίδιο κέρδος. Η πρώτη κερδίζει σταθερά 1% τον μήνα. Η δεύτερη κάνει +20%, μετά -18%, μετά +19%... Ποια θα προτιμούσες; Σχεδόν όλοι λένε την πρώτη — γιατί είναι *λιγότερο επικίνδυνη*. Άρα το μέσο κέρδος δεν αρκεί: πρέπει να μετράμε και τον κίνδυνο.

Μέσος και διακύμανση. Η αναμενόμενη τιμή ή απλώς ο μέσος (mean), που συμβολίζουμε $\mu = \mathbb{E}[R]$, είναι το «τυπικό» κέρδος. Παράδειγμα: για αποδόσεις $\{0,01, -0,01, 0,03\}$ ο μέσος είναι $\mu = \frac{0,01-0,01+0,03}{3} = 0,01$.

Η διακύμανση (variance) $\sigma^2 = \text{Var}(R) = \mathbb{E}[(R - \mu)^2]$ μετράει πόσο «σκορπισμένες» είναι οι αποδόσεις γύρω από τον μέσο, και η τυπική απόκλιση (standard deviation) $\sigma = \sqrt{\sigma^2}$ είναι το ίδιο σε ίδιες μονάδες. Παράδειγμα: αν κερδίζεις ακριβώς το ίδιο κάθε μέρα, $\sigma = 0$ (μηδενικός κίνδυνος)· όσο πιο άγριες οι διακυμάνσεις, τόσο μεγαλύτερο το σ .

Ο δείκτης Sharpe. Ο πιο διάσημος τρόπος να συνδυάσεις κέρδος και κίνδυνο είναι ο δείκτης Sharpe — κέρδος ανά μονάδα κινδύνου:

$$S = \frac{\mu}{\sigma}.$$

Παράδειγμα: $\mu = 0,001$ ανά μέρα και $\sigma = 0,01$ δίνουν ημερήσιο $S = 0,1$. Επειδή συνήθως μιλάμε σε ετήσια βάση, πολλαπλασιάζουμε με $\sqrt{252}$ (τόσες είναι οι μέρες συναλλαγών στον χρόνο), οπότε ο ετήσιος δείκτης γίνεται $0,1 \cdot \sqrt{252} \approx 1,59$. Όσο μεγαλύτερος ο S , τόσο καλύτερη η ποιότητα της στρατηγικής ανά μονάδα ρίσκου.

5 Το κρυφό πρόβλημα του δείκτη Sharpe

Ο Sharpe μετράει τον κίνδυνο μόνο μέσω της τυπικής απόκλισης σ . Όμως το σ τιμωρεί εξίσου τα μεγάλα κέρδη και τις μεγάλες ζημιές — τα βλέπει και τα δύο ως «αποκλίσεις από τον μέσο». Αυτό είναι λάθος για έναν επενδυτή: κανείς δεν φοβάται ένα ξαφνικό κέρδος· φοβάται μια ξαφνική κατάρρευση (crash).

Με απλά λόγια: Δύο στρατηγικές μπορεί να έχουν ακριβώς τον ίδιο μέσο και την ίδια τυπική απόκλιση — άρα τον ίδιο δείκτη Sharpe — και όμως η μία να βγάζει σπάνια μεγάλα κέρδη και η άλλη σπάνιες καταστροφικές πτώσεις. Ο Sharpe τις βλέπει πανομοιότυπες. Δεν διακρίνει το σχήμα του κινδύνου.

Χρειαζόμαστε λοιπόν ένα μέτρο που να «βλέπει» αν οι ακραίες κινήσεις πέφτουν στην καλή ή στην κακή πλευρά. Για να το φτιάξουμε, ξεκινάμε από μια απλή ψυχολογική αλήθεια.

6 Χρησιμότητα: γιατί φοβόμαστε πιο πολύ τις απώλειες

Σκέψου το εξής: το να κερδίσεις ξαφνικά 1000 ευρώ είναι ευχάριστο. Το να χάσεις ξαφνικά 1000 ευρώ είναι πιο δυσάρεστο απ' όση ευχάριστο ήταν το κέρδος. Αυτή η ασυμμετρία — ότι ο πόνος της απώλειας είναι μεγαλύτερος από τη χαρά του ίσου κέρδους — λέγεται **αποστροφή κινδύνου** (risk aversion).

Τη μοντελοποιούμε με μια **συνάρτηση χρησιμότητας** (utility function) $u(x)$: πόσο «α-ξίζει» ψυχολογικά ένα ποσό x . Διαλέγουμε την εκθετική:

$$u(x) = -\frac{1}{\theta} e^{-\theta x}.$$

Η παράμετρος θ (θήτα) είναι ο **βαθμός αποστροφής κινδύνου**: $\theta = 0$ σημαίνει αδιαφορία για το ρίσκο, μεγάλο θ σημαίνει μεγάλο φόβο.

Με απλά λόγια: Η συνάρτηση είναι «κοίλη» (concave): καμπυλώνει προς τα κάτω. Αυτό σημαίνει ότι κάθε επιπλέον ευρώ σου δίνει λίγο λιγότερη ικανοποίηση από το προηγούμενο — και αντίστροφα, κάθε ευρώ που χάνεις πονάει όλο και πιο πολύ. Έτσι μαθηματικά αποτυπώνεται ο φόβος των απωλειών.

7 Το ισοδύναμο βεβαιότητας (certainty equivalent)

Τώρα κάνουμε την εξής ερώτηση: «Τι σίγουρο ποσό θα δεχόσουν, αντί να παίζεις ένα τυχερό παιχνίδι με αβέβαιη απόδοση R » Αυτό το σίγουρο ποσό λέγεται **ισοδύναμο βεβαιότητας** (certainty equivalent). Με την εκθετική χρησιμότητα προκύπτει ο τύπος:

$$CE_{\theta}(R) = -\frac{1}{\theta} \log \mathbb{E}[e^{-\theta R}].$$

Εδώ το e^x είναι η **εκθετική** συνάρτηση (μεγαλώνει πολύ γρήγορα: $e^1 \approx 2,7$, $e^{2,5} \approx 12$) και το $\log$ είναι ο **λογάριθμος**, η αντίστροφή της.

Ένα πολύ διαφωτιστικό παράδειγμα. Παίζεις ένα δίκαιο στοίχημα: με πιθανότητα 50% κερδίζεις $+0,10$ και με 50% χάνεις $-0,10$. Ο μέσος του είναι 0 — ούτε κερδίζεις ούτε χάνεις κατά μέσο όρο. Όμως για έναν ρισκόφοβο με $\theta = 10$:

$$CE_{10} = -\frac{1}{10} \log\left(\frac{1}{2}e^{-1} + \frac{1}{2}e^1\right) = -\frac{1}{10} \log(1,543) \approx -0,043.$$

Δηλαδή ο ρισκόφοβος αποτιμά αυτό το «δίκαιο» παιχνίδι σε $-4,3\%$: θα πλήρωνε για να το αποφύγει! Με $\theta = 20$ η αποτίμηση πέφτει στο $\approx -6,6\%$ — όσο πιο ρισκόφοβος, τόσο πιο αρνητικά βλέπει την αβεβαιότητα.

Με απλά λόγια: Το CE_{θ} δεν είναι απλώς ο μέσος. Αφαιρεί μια «ποινή κινδύνου» από τον μέσο, και το μέγεθος αυτής της ποινής το ελέγχει το θ . Στο επόμενο βήμα θα δούμε ότι αυτή η ποινή είναι ακριβώς αυτό που χρειαζόμαστε για να «δούμε» τα crashes.

8 Ροπές: γιατί το θ τα βλέπει όλα

Για να καταλάβουμε τι κρύβει το CE_{θ} , πρέπει να ξέρουμε πώς περιγράφουμε το «σχήμα» μιας κατανομής αποδόσεων. Το κάνουμε με τέσσερις αριθμούς, τις **ροπές** (moments):

- $\kappa_1 = \mu$ — ο **μέσος** (mean): πού βρίσκεται το «κέντρο».
- $\kappa_2 = \sigma^2$ — η **διακύμανση** (variance): πόσο «φαρδιά» είναι.
- κ_3 — η **ασυμμετρία** (skewness): προς ποια πλευρά «γέρνει». Θετική κ_3 = ουρά προς τα δεξιά (σπάνια μεγάλα κέρδη — καλό)· αρνητική κ_3 = ουρά προς τα αριστερά (σπάνια μεγάλα crash — κακό).
- κ_4 — η **χύρτωση** (kurtosis): πόσο «παχιές» είναι οι ουρές, δηλαδή πόσο συχνά συμβαίνουν ακραία γεγονότα (fat tails).

Το θαύμα είναι το εξής. Αν αναπτύξουμε τον τύπο του CE_{θ} σε σειρά, παίρνουμε:

$$CE_{\theta} = \underbrace{\mu}_{\text{απόδοση}} - \underbrace{\frac{\theta}{2} \sigma^2}_{\text{φόβος διακύμανσης}} + \underbrace{\frac{\theta^2}{6} \kappa_3}_{\text{θέλει θετική ασυμμετρία}} - \underbrace{\frac{\theta^3}{24} \kappa_4}_{\text{μισεί τις παχιές ουρές}} + \dots$$

Δες τι λέει αυτό, όρο προς όρο:

- Όταν $\theta = 0$: μένει μόνο το μ . Αδιαφορείς για το ρίσκο, θες μόνο κέρδος.
- Μικρό θ : προσθέτεις την ποινή $-\frac{\theta}{2}\sigma^2$ — αυτό είναι σαν τον Sharpe (κέρδος εναντίον διακύμανσης).

- Μεγαλύτερο θ : ενεργοποιείται ο όρος $+\frac{\theta^2}{6}\kappa_3$ — αρχίζεις να *ανταμείβεις* τη θετική ασυμμετρία και να τιμωρείς τα crashes.
- Ακόμη μεγαλύτερο θ : ο όρος $-\frac{\theta^3}{24}\kappa_4$ τιμωρεί τα ακραία γεγονότα (τις παχιές ουρές).

Ορισμός 1 (Τι κερδίζουμε με μία παράμετρο). Με μία μόνο παράμετρο θ σταθμίζουμε αυτόματα όλες τις ροπές. Ο δείκτης Sharpe ($= \mu/\sigma$) χρησιμοποιεί μόνο τις δύο πρώτες· δομικά *δεν* περιέχει ασυμμετρία και κύρτωση. Γ' αυτό δύο στρατηγικές με ίδιο μ, σ αλλά αντίθετη ασυμμετρία ξεχωρίζουν μόνο από το CE_θ .

Με απλά λόγια: Αυτή ακριβώς είναι η καρδιά της πρότασής μας. Αντί να κρίνουμε τη στρατηγική με τον τυφλό-στα-crashes Sharpe, την κρίνουμε με το CE_θ που «βλέπει» αυτόματα ασυμμετρία και ουρές, ρυθμιζόμενα από το ένα κουμπί θ .

9 Από το μέτρο στην ανταμοιβή: το DER

Ένα πρόβλημα: ο πράκτορας μαθαίνει βήμα-βήμα, μέρα-μέρα, άρα χρειάζεται μια ανταμοιβή *κάθε μέρα*. Το CE_θ όμως υπολογίζεται στο τέλος. Λύση: κρατάμε έναν **κινητό μέσο** (exponential moving average, EMA) που ενημερώνεται κάθε μέρα:

$$M_t = (1 - \eta) M_{t-1} + \eta e^{-\theta R_t},$$

όπου η είναι ο ρυθμός με τον οποίο ξεχνάμε τα παλιά δεδομένα (η «μνήμη»: μικρό η = μακρά μνήμη). Το M_t είναι ένα «ζωντανό» $\mathbb{E}[e^{-\theta R}]$.

Η ανταμοιβή κάθε μέρα — που την ονομάζουμε **Differential Entropic Reward** (DER) — είναι πόσο βελτιώθηκε το τρέχον ισοδύναμο βεβαιότητας:

$$DER_t = -\frac{1}{\theta} \log \frac{M_t}{M_{t-1}}.$$

Με απλά λόγια: Δύο ωραίες ιδιότητες. Πρώτον, αν προσθέσεις όλες τις ημερήσιες ανταμοιβές DER_t , το άθροισμα ισούται με τη *συνολική* βελτίωση του CE_θ — άρα μεγιστοποιώντας τις μικρές καθημερινές ανταμοιβές, μεγιστοποιείς το τελικό ρισκο-προσαρμοσμένο σκορ. Δεύτερον, λόγω του $e^{-\theta R}$, μια μεγάλη ζημιά τιμωρείται *εκθετικά* (πάρα πολύ), ενώ ένα ίσο κέρδος ανταμείβεται μέτρια. Αυτή η ασυμμετρία είναι ακριβώς η προστασία από τα crashes που ο Sharpe δεν έχει.

Για σύγκριση: το κλασικό αντίστοιχο που χρησιμοποιεί ο Sharpe λέγεται **Differential Sharpe Ratio** (DSR) και χτίζεται με τον ίδιο τρόπο, αλλά κρατώντας κινητούς μέσους του R και του R^2 (δηλαδή του μ και του σ). Η μόνη του παράμετρος είναι η μνήμη η — *δεν* έχει κουμπί κινδύνου σαν το θ .

10 Πώς μαθαίνει ο πράκτορας: η ανάβαση κλίσης

Ορίσαμε τι θεωρούμε καλό (την ανταμοιβή DER). Μένει το πιο πρακτικό ερώτημα: *πώς* βρίσκει ο πράκτορας τα σωστά βάρη w ?

Θυμήσου ότι η πολιτική είναι $F_t = \tanh(w^\top x_t + b)$. Όλο το παιχνίδι είναι να βρούμε τα βάρη w που κάνουν τη *συνολική* ανταμοιβή όσο μεγαλύτερη γίνεται:

$$\max_w \sum_t DER_t \quad \left(= \text{η τελική βελτίωση του } CE_\theta \right).$$

Η αναλογία του λόφου. Φαντάσου ότι στέκεσαι σε έναν λόφο μέσα στην ομίχλη και θες να φτάσεις στην κορυφή (τη μέγιστη ανταμοιβή). Δεν βλέπεις μακριά, αλλά νιώθεις την κλίση του εδάφους κάτω από τα πόδια σου. Κάνεις ένα μικρό βήμα προς τα πάνω, ξανανιώθεις την κλίση, κάνεις άλλο βήμα — και σιγά-σιγά ανεβαίνεις. Αυτό λέγεται **ανάβαση κλίσης** (gradient ascent).

Η κλίση. Η «κλίση» εδώ είναι η **παράγωγος** της συνολικής ανταμοιβής ως προς τα βάρη: σου λέει προς τα πού και πόσο αλλάζει η ανταμοιβή αν πειράξεις λίγο κάθε βάρος. Τη συμβολίζουμε $\nabla_w(\sum_t DER_t)$.

Ο κανόνας ενημέρωσης. Σε κάθε βήμα, σπρώχνουμε τα βάρη λίγο προς την κατεύθυνση που αυξάνει την ανταμοιβή:

$$w \leftarrow w + \alpha \nabla_w \left(\sum_t DER_t \right),$$

όπου α είναι ο **ρυθμός μάθησης** (learning rate) — το μέγεθος του βήματος. Μικρό α : αργά αλλά σταθερά· μεγάλο α : γρήγορα αλλά με κίνδυνο να «προσπεράσεις» την κορυφή.

Με απλά λόγια: Γιατί χτίσαμε το DER ομαλό. Για να υπολογίσεις την κλίση, η ανταμοιβή πρέπει να είναι **παραγωγίσιμη** (differentiable) — να μπορείς να βρεις παράγωγο. Ακριβώς γι' αυτό διαλέξαμε τις ομαλές συναρτήσεις e^x και $\log$ στο DER, και τη $\tanh$ στην πολιτική: όλη η αλυσίδα είναι παραγωγίσιμη, άρα ο πράκτορας μπορεί να «νιώσει την κλίση» και να μάθει.

Επεισόδια. Δεν φτάνει ένα πέρασμα. Περνάμε τα ιστορικά δεδομένα πολλές φορές — κάθε πέρασμα λέγεται **εποχή** (epoch). Σε κάθε εποχή τα βάρη βελτιώνονται λίγο, ώσπου η ανταμοιβή σταματά να αυξάνεται: τότε λέμε ότι ο πράκτορας **συνέκλινε** (έμαθε). Όταν τροφοδοτούμε την ανταμοιβή πίσω μέσα από την παραγωγίσιμη θέση με αυτόν τον τρόπο, η μέθοδος ονομάζεται Recurrent Reinforcement Learning — η κλασική προσέγγιση των Moody & Saffell.

11 Οι τρεις «προσωπικότητες» του θ

Το θ είναι το μοναδικό ουσιαστικό κουμπί του αλγορίθμου, και έχει τρεις ισοδύναμες ερμηνείες:

1. **Βαθμός αποστροφής κινδύνου.** Πόσο φοβάσαι την αβεβαιότητα. $\theta = 0$ ουδέτερος, μεγάλο θ πολύ προσεκτικός.
2. **Πόσες ροπές τιμωρείς.** Όπως είδαμε, όσο μεγαλώνει το θ , τόσο περισσότερο μετράνε η διακύμανση, μετά η ασυμμετρία, μετά οι ουρές.
3. **Πόσο δεν εμπιστεύεσαι το μοντέλο σου.** Υπάρχει μια ισοδύναμη μορφή του CE_θ που λέει: «βελτιστοποίησε για τη χειρότερη εύλογη αγορά, όχι μόνο για αυτή που νομίζεις ότι ισχύει». Μεγάλο θ = υποθέτεις πιο εχθρικό σενάριο.

Με απλά λόγια: Στα πειράματά μας, καθώς ανεβάσαμε το θ , ο πράκτορας γινόταν ολοένα πιο συντηρητικός: η απόδοση μίκραινε αλλά η μέγιστη πτώση κατέρρεε (από -26% σε $-0,4\%$). Το θ λειτουργεί στην πράξη σαν ομαλός διακόπτης που ανταλλάσσει απόδοση για προστασία.

12 Για τους περίεργους: η σύνδεση με τον βέλτιστο έλεγχο

Αυτή η ενότητα είναι προαιρετική — δεν χρειάζεται να την κατανοήσεις πλήρως.

Η ίδια ιδέα υπάρχει σε «συνεχή χρόνο», στη θεωρία του βέλτιστου ελέγχου (optimal control). Εκεί η κατάσταση X_t (π.χ. ο πλούτος σου) εξελίσσεται με μια στοχαστική εξίσωση

$$dX = \underbrace{b}_{\text{ολίσθηση}} dt + \underbrace{\sigma}_{\text{διάχυση}} dW,$$

όπου η ολίσθηση (drift) b είναι η μέση τάση, η διάχυση (diffusion) σ είναι η ένταση της τυχαιότητας, και W είναι η κίνηση Brown (Brownian motion) — ο «καθαρός τυχαίος θόρυβος» της αγοράς. Η συνάρτηση αξίας (value function) V λέει «πόσο αξίζει» να βρίσκεσαι σε μια κατάσταση αν παίζεις βέλτιστα.

Η εξίσωση που τη διέπει (Hamilton–Jacobi–Bellman, HJB), στην ρισκο-ευαίσθητη εκδοχή της, αποκτά έναν επιπλέον όρο που τιμωρεί την έκθεση στη μεταβλητότητα — και αυτός ο όρος ελέγχεται πάλι από το ίδιο θ . Όταν $\theta \rightarrow 0$, ο όρος εξαφανίζεται και επιστρέφουμε στην κλασική θεωρία.

Με απλά λόγια: Με λίγα λόγια: το DER δεν είναι ένα αυθαίρετο τρικ. Είναι η διακριτή, πρακτική «σκιά» μιας θεμελιωμένης εξίσωσης του βέλτιστου ελέγχου. Αυτή η θεωρητική ρίζα είναι που ξεχωρίζει την πρότασή μας από τις δεκάδες αυθαίρετες συναρτήσεις ανταμοιβής της βιβλιογραφίας.

13 Πώς κρίνουμε μια στρατηγική στην πράξη

Αφού εκπαιδεύσουμε τον πράκτορα, τον δοκιμάζουμε σε δεδομένα που δεν έχει ξαναδεί (αυτό λέγεται **οπισθοδοκιμή** ή ιστορικός έλεγχος, backtest) και μετράμε:

- **Καμπύλη κεφαλαίου** (equity curve): η εξέλιξη της αξίας του χαρτοφυλακίου, $\prod_t(1+R_t)$, ξεκινώντας από 1. *Παράδειγμα:* αποδόσεις +0,10 και μετά −0,05 δίνουν $1 \cdot 1,10 \cdot 0,95 = 1,045$.
- **Δείκτης Sharpe:** όπως ορίστηκε, ετησιοποιημένος με $\sqrt{252}$.
- **Δείκτης Sortino:** σαν τον Sharpe, αλλά στον παρονομαστή βάζει μόνο την απόκλιση των ζημιών — δεν τιμωρεί την «καλή» μεταβλητότητα των κερδών.
- **Μέγιστη πτώση** (maximum drawdown, MDD): η μεγαλύτερη πτώση από κορυφή σε κοιλάδα. *Παράδειγμα:* αν η αξία πάει $1,00 \rightarrow 1,40 \rightarrow 1,10$, η πτώση είναι $\frac{1,10-1,40}{1,40} \approx -21\%$. Μετράει τον χειρότερο πόνο που θα ένιωθε ένας επενδυτής.

Με απλά λόγια: Σημαντικό για το τι ισχυριζόμαστε: ο σκοπός του DER δεν είναι να βγάξει το μεγαλύτερο κέρδος, αλλά την καλύτερη απόδοση ανά μονάδα κινδύνου και τη μικρότερη πτώση. Σε αγορά που απλώς ανεβαίνει, μια προσεκτική στρατηγική χάνει από το «αγόρασε-και-κράτα» — αυτό είναι αναμενόμενο. Η αξία της φαίνεται εκεί που υπάρχει κίνδυνος: στις πτώσεις.

14 Τα κομμάτια μαζί: ο πλήρης κύκλος

Ας ενώσουμε τώρα όλα όσα είδαμε σε μία εικόνα. Κάθε μέρα, και ξανά και ξανά πάνω στα δεδομένα, εκτελείται ο εξής κύκλος:

$$\underbrace{x_t}_{\text{κατάσταση}} \rightarrow \underbrace{w}_{\text{πολιτική}} \rightarrow \underbrace{F_t}_{\text{θέση}} \rightarrow \underbrace{R_t}_{\text{κέρδος}} \rightarrow \underbrace{DER_t}_{\text{ανταμοιβή}} \rightarrow \underbrace{\nabla_w}_{\text{κλίση}} \rightarrow \underbrace{w_{\text{νέο}}}_{\text{μάθηση}} \rightarrow \dots$$

Διαβάζοντάς τον από αριστερά: ο πράκτορας βλέπει την κατάσταση· η πολιτική (με τα τρέχοντα βάρη) επιλέγει θέση· η θέση παράγει κέρδος· το κέρδος μετατρέπεται σε ανταμοιβή DER· η ανταμοιβή δίνει την κλίση· η κλίση ενημερώνει τα βάρη — και ο κύκλος επαναλαμβάνεται.

Και εδώ είναι η σύνδεση που ενώνει όλο το κείμενο:

- Η **ενισχυτική μάθηση** δίνει τη *μηχανή* που μαθαίνει (τον κύκλο).
- Η **ανταμοιβή DER** δίνει στη μηχανή τις *αξίες* της — το τι θεωρεί καλό (απόδοση προσαρμοσμένη στον κίνδυνο, με προστασία από τα crashes).
- Το θ είναι το κουμπί που ρυθμίζει αυτές τις αξίες: μεγάλο $\theta \Rightarrow$ η ανταμοιβή τιμωρεί πιο σκληρά τις ζημιές $\Rightarrow$ η κλίση σπρώχνει τα βάρη προς πιο προσεκτικές θέσεις $\Rightarrow$ η μηχανή μαθαίνει πιο συντηρητική στρατηγική.
- Η **θεωρία** (ροπές, ισοδύναμο βεβαιότητας, HJB) εξηγεί *γιατί* αυτή η ανταμοιβή είναι θεμελιωμένη και όχι αυθαίρετη.

Με απλά λόγια: Με μία πρόταση: η *ενισχυτική μάθηση* είναι το «πώς μαθαίνει», το *DER* είναι το «τι θεωρεί καλό», και το θ είναι «πόσο φοβάται τον κίνδυνο». Αλλάζοντας μόνο το θ αλλάζεις τη συμπεριφορά που θα μάθει ο πράκτορας — από επιθετική σε αμυντική — χωρίς να πειράξεις τίποτε άλλο.

15 Πίνακας συμβόλων

Σύμβολο	Ελληνικός όρος (αγγλικός)	Παράδειγμα
t	μέρα / χρονικό βήμα	$t = 1, 2, 3, \dots$
p_t	τιμή (price)	100 ευρώ
r_t	απόδοση (return)	$100 \rightarrow 102 \Rightarrow r_t = 0,02$
F_t	θέση (position)	+1 αγορά, -1 πώληση, 0 εκτός
δ	κόστος συναλλαγής (cost)	0,0005
R_t	κέρδος στρατηγικής (trading return)	$F_{t-1}r_t - \delta F_t - F_{t-1} $
x_t	κατάσταση (state)	8 τελευταίες αποδόσεις
w, b	βάρη & σταθερά (weights)	μαθαίνονται από τον πράκτορα
$\tanh$	συνάρτηση συμπίεσης	$\tanh(2) \approx 0,96$
μ	μέσος (mean)	μέση απόδοση
σ, σ^2	τυπ. απόκλιση & διακύμανση	μέτρο διασποράς
S	δείκτης Sharpe	$0,1 \cdot \sqrt{252} \approx 1,59$
θ	αποστροφή κινδύνου (risk aversion)	0 ουδέτερος, 50 προσεκτικός
$u(x)$	συνάρτηση χρησιμότητας	$-\frac{1}{\theta}e^{-\theta x}$
CE_θ	ισοδύναμο βεβαιότητας	δίκαιο στοίχημα $\rightarrow -4,3\%$
η	ρυθμός μνήμης (EMA rate)	$\eta = 0,01 \approx 100$ μέρες
M_t	κινητός μέσος του $e^{-\theta R}$	«ζωντανό» $\mathbb{E}[e^{-\theta R}]$
DER_t	ανταμοιβή μας ανά βήμα	$-\frac{1}{\theta} \log(M_t/M_{t-1})$
$\kappa_1 - \kappa_4$	ροπές: μέσος, διακύμ., ασυμμετρία, κύρτωση	ασυμμετρία < 0 = κίνδυνος crash
α	ρυθμός μάθησης (learning rate)	μέγεθος βήματος στην ανάβαση
∇_w	κλίση ως προς τα βάρη (gradient)	κατεύθυνση αύξησης ανταμοιβής
V	συνάρτηση αξίας (value function)	βέλτιστος έλεγχος
MDD	μέγιστη πτώση (max drawdown)	$1,4 \rightarrow 1,1 \Rightarrow -21\%$